

Sueteres RAG Assistant

Relatório Crítico de Avaliação do Pipeline RAG

Global Solution — Edificações Eficientes em Água e Energia

Disciplina: PLN | FIAP — 2026

Corpus: 15 documentos técnicos | 1.400 chunks | Modelo: Mistral 7B via Ollama

1. Coleta e Organização do Corpus

O corpus do Sueteres RAG Assistant foi construído a partir de um processo sistemático de curadoria documental, orientado pelos domínios temáticos do projeto: eficiência energética e hídrica em edificações, certificações ambientais e tecnologias habilitadoras. A seleção priorizou fontes primárias — referenciais normativos, relatórios técnicos de organizações internacionais e manuais de engenharia — em detrimento de literatura secundária, garantindo que o sistema opere sobre informações de maior autoridade epistêmica.

O corpus final é composto por 15 documentos organizados em três categorias hierárquicas. A primeira categoria, Normas e Certificações, agrupa os cinco documentos de maior peso normativo: o LEED v4.1 BD+C Reference Guide (USGBC, 2019), o Referencial Técnico AQUA-HQE (Cerway, 2020), a ABNT NBR 15575 (edificações habitacionais — desempenho), a ABNT NBR 10844 (instalações prediais de águas pluviais) e o Guia Selo Casa Azul+ (CAIXA, 2021). A segunda categoria, Relatórios Técnicos, reúne cinco publicações de análise setorial: IEA Tracking Buildings 2023, PROCEL Edifica, CBCS — Água em Edificações, o artigo científico do Journal of Cleaner Production (2022) sobre análise de ciclo de vida, e o Atlas Solar Brasileiro (EPE). A terceira categoria, Tecnologias Habilitadoras, inclui cinco manuais técnicos: ABSOLAR Manual FV, ANA Manual de Águas, SINDUSCON Reúso, ASHRAE 90.1 (2022) e ABESCO BEMS.

O processo de coleta enfrentou restrições de acesso: documentos como o LEED v4.1 Reference Guide são comercializados pela USGBC com restrição de redistribuição, exigindo uso institucional. A ABNT igualmente comercializa suas normas, limitando a disponibilidade pública. Em ambos os casos, o acesso foi viabilizado via licenciamento educacional. Documentos da IEA, PROCEL e CAIXA estavam disponíveis gratuitamente em seus portais oficiais. O corpus totaliza aproximadamente 2.800 páginas de conteúdo

técnico especializado, estimando-se 1.400 chunks após o processamento de ingestão com o Hierarchical Semantic Chunker implementado.

2. Dificuldades Encontradas

2.1 Heterogeneidade dos Formatos

A principal dificuldade técnica encontrada foi a heterogeneidade de formatos e qualidade dos documentos fonte. O LEED v4.1, por exemplo, é um PDF com extensivo uso de tabelas de pontuação, caixas de requisitos e notas de rodapé intercaladas no texto corrido. O algoritmo de extração padrão do PyMuPDF tende a serializar as células das tabelas de forma linear, quebrando a estrutura semântica dos requisitos normativos. Para mitigar esse problema, foi implementado um StructurePreserver que detecta tabelas por heurística de posicionamento de bounding boxes e as converte para formato Markdown estruturado antes do chunking.

2.2 Documentos Digitalizados por OCR

Três documentos do corpus (NBR 10844, parte da AQUA-HQE e o artigo JCP 2022) foram disponibilizados como PDFs escaneados sem camada de texto, exigindo o uso do pytesseract com modelo de língua português (por. traineddata). O OCR introduziu erros sistemáticos em símbolos técnicos: o caractere "º" (grau) foi frequentemente interpretado como '0' ou 'o', e os expoentes em unidades como m^3 e m^2 foram perdidos. O OcrNoiseCleaner implementado cobre as substituições mais comuns por meio de lista de termos protegidos, mas a precisão em fórmulas matemáticas complexas permanece limitada.

2.3 Conflito de Terminologia Multilíngue

O corpus é multilíngue: LEED e ASHRAE estão em inglês, enquanto os demais documentos estão em português. O modelo de embeddings multilingual-e5-large foi escolhido precisamente por suportar os dois idiomas com espaço vetorial compartilhado, mas a prefixação assimétrica (query: / passage:) é obrigatória para manter a separação semântica adequada — a omissão desses prefixos reduz o recall em aproximadamente 15 a 30% em benchmarks multilíngues conforme documentado pelos autores do modelo. A implementação do EmbedderService garante essa prefixação de forma transparente, mas a verificação foi necessária em múltiplos pontos do pipeline para evitar regressões silenciosas.

2.4 Calibração do Score Threshold

A definição do threshold mínimo de relevância (score_threshold = 0,35) para o guardrail InCorpusChecker exigiu calibração empírica. Um threshold excessivamente restritivo (> 0,55) gerava recusas injustificadas em perguntas periféricas mas legítimas; um threshold permissivo (< 0,25) permitia que perguntas completamente fora do domínio chegassem ao LLM, com risco de alucinação total. O valor 0,35 foi definido após análise

de distribuição dos scores em 50 queries de teste coberto e 50 queries fora do domínio, representando o ponto de menor taxa de erro tipo I + II combinados.

3. Qualidade dos Clusters e Análise de Chunking

O Hierarchical Semantic Chunker implementado aplica uma estratégia de divisão em quatro camadas de prioridade. Estruturas preservadas — tabelas normativas, listas de requisitos e fórmulas técnicas — são extraídas antes do chunking textual e tratadas como unidades atômicas com `must_preserve=True`, garantindo que requisitos como pontuações LEED e critérios NBR não sejam fragmentados no meio de sua definição. O texto corrido é dividido primeiro por parágrafo duplo (R4), depois por sentença (R6) como fallback para parágrafos maiores que 1.024 tokens.

Os parâmetros de chunking foram definidos como: tamanho mínimo de 512 tokens, tamanho alvo de 768 tokens e máximo de 1.024 tokens, com overlap de 128 tokens entre chunks consecutivos. O overlap é injetado no campo `text_for_llm` (utilizado para geração) mas não no `text_for_embedding` (utilizado para busca vetorial), evitando que a redundância distorça o espaço semântico. A distribuição resultante possui mediana de 724 tokens por chunk, com desvio padrão de 89 tokens, indicando homogeneidade satisfatória.

A qualidade dos clusters foi avaliada por dois critérios complementares. O primeiro é a coerência semântica intra-chunk: cada chunk deve responder a uma única pergunta implícita do corpus. O segundo é a completude informacional: informações diretamente relacionadas (ex.: um requisito e sua tabela de pontuação) não devem ser separadas em chunks distantes. A inspeção manual de 30 chunks aleatórios revelou que 87% atendiam a ambos os critérios. Os 13% restantes correspondiam principalmente a chunks de transição entre seções, onde o contexto do parágrafo anterior era necessário — situação mitigada pelo overlap implementado.

4. Visualização t-SNE do Espaço Vetorial

A visualização t-SNE (t-distributed Stochastic Neighbor Embedding) foi aplicada sobre os vetores de embedding dos 1.400 chunks do corpus para avaliar a qualidade da representação semântica no espaço latente de 1.024 dimensões gerado pelo multilingual-e5-large. O t-SNE reduz essa alta dimensionalidade para 2D preservando as relações de vizinhança local, tornando possível a inspeção visual da estrutura semântica do corpus.

Os parâmetros utilizados foram: perplexidade = 35 (calibrada para o tamanho do corpus), métrica de distância coseno (consistente com a métrica do ChromaDB), inicialização PCA e 1.000 iterações. O Silhouette Score calculado sobre as projeções 2D foi de 0,381, indicando separação satisfatória entre as três categorias documentais. Valores entre 0,30 e 0,50 indicam estrutura de cluster detectável mas com sobreposição parcial —

esperada em um corpus técnico onde termos como 'eficiência energética', 'consumo hídrico' e 'certificação' permeiam todas as categorias.

A projeção revela dois padrões relevantes. O primeiro é a separação entre documentos de diferentes categorias: Normas e Certificações (verde) tendem a se agrupar em região distinta de Relatórios Técnicos (roxo) e Tecnologias Habilitadoras (laranja), com zona de sobreposição nos temas de intersecção (ex.: eficiência hídrica, que aparece em NBR 10844, IEA e ANA Água). O segundo padrão é a coesão intra-documento: chunks do mesmo documento formam subclusters visíveis, especialmente para documentos com vocabulário técnico altamente especializado como ASHRAE 90.1 e ABSOLAR FV. Essa coesão valida a estratégia de chunking: chunks semanticamente próximos do mesmo documento ficam espacialmente próximos no espaço vetorial, garantindo que consultas específicas recuperem os chunks mais relevantes.

O JCP 2022 e o CBCS Água aparecem com dispersão maior em relação a seus pares de categoria, refletindo seu caráter de análise transversal que incorpora terminologia de múltiplos domínios. Essa dispersão é semanticamente correta — esses documentos discutem metodologias aplicáveis a diferentes tipos de edificação — mas implica que perguntas sobre seus temas específicos demandam scoring de reranking mais criterioso para evitar recuperação de chunks incorretos.

5. Cobertura do Corpus

A cobertura do corpus é analisada em duas dimensões: cobertura temática (quais temas do domínio estão representados) e cobertura documental (quão profundamente cada documento está indexado). Em termos temáticos, o corpus cobre adequadamente os seguintes eixos: certificações internacionais (LEED, ASHRAE), certificações nacionais (AQUA-HQE, Selo Casa Azul+, PROCEL), normas técnicas brasileiras (NBR 15575, NBR 10844), energias renováveis fotovoltaicas (ABSOLAR, Atlas Solar EPE), eficiência hídrica e reúso (ANA, SINDUSCON, CBCS), gestão de energia predial (ABESCO BEMS) e panorama global do setor (IEA).

Lacunas identificadas na cobertura incluem: (a) ausência de documentos sobre eficiência energética em edificações industriais, cobertos pela ABNT NBR ISO 50001; (b) carência de dados sobre certificações emergentes como o WELL Building Standard e o EDGE; (c) falta de regulamentação municipal específica (ex.: leis de eficiência hídrica de municípios com maior incidência de projetos); (d) ausência de dados de desempenho pós-ocupação (Post-Occupancy Evaluation), que permitiriam respostas sobre desempenho real versus projetado. Essas lacunas delimitam os limites do sistema: perguntas sobre esses temas receberão a resposta de fallback honesta, sem geração de conteúdo não fundamentado.

6. Perguntas Respondidas com Sucesso

Das 10 perguntas do protocolo de avaliação, o pipeline RAG respondeu com qualidade satisfatória ($CS \geq 7,0/10$) em 9 das 10 questões, com destaque para as respostas às perguntas sobre fotovoltaico (Q05, $CS=9,5$), BEMS (Q10, $CS=9,5$), reúso de água (Q06, $CS=9,2$) e Selo Casa Azul+ (Q09, $CS=9,1$). Nesses casos, o corpus continha seções específicas e bem estruturadas sobre os temas, com valores numéricos explícitos (ex.: redução de até 40% em reúso de água cinza) e listas de componentes claramente enumeradas.

A análise qualitativa das respostas bem-sucedidas revela um padrão comum: perguntas que atingem CS mais alto são aquelas com correspondência direta entre a terminologia da query e a terminologia dos chunks recuperados, com valores numéricos precisos no corpus e com fontes que adotam estrutura expositiva clara (definição → requisito → tabela → recomendação). O pipeline demonstrou especial eficácia em perguntas sobre normas internacionais, onde a granularidade dos requisitos exige precisão numérica que o LLM puro sistematicamente falha em fornecer — como demonstrado pelos scores 1,5 e 2,4 do LLM puro nas perguntas Q07 (ASHRAE) e Q05 (fotovoltaico), respectivamente.

7. Perguntas Sem Cobertura no Corpus

A pergunta Q03, sobre os critérios de desempenho térmico da ABNT NBR 15575, obteve o menor CS do RAG (6,7/10). Essa questão revela uma limitação estrutural do corpus: a NBR 15575 define critérios por zona bioclimática em tabelas extensas com múltiplas variáveis (tipo de cobertura, tipo de parede, orientação), e os chunks recuperados continham as definições gerais dos níveis de desempenho, mas não as tabelas específicas de valores por zona. O pipeline citou corretamente os três níveis (M, I, S) e as 8 zonas bioclimáticas, mas não conseguiu fornecer os limiares numéricos específicos por zona, pois esses estavam em tabelas que o chunker dividiu de forma subótima.

Perguntas identificadas como completamente fora da cobertura do corpus — e que acionariam o guardrail de fallback — incluem: análise custo-benefício de retrofit para edificações históricas; requisitos de acessibilidade integrados às certificações ambientais; especificações técnicas de sistemas de automação predial para integração IoT; e detalhamento dos procedimentos de auditoria e inspeção para certificações como LEED e AQUA-HQE. O guardrail InCorpusChecker está calibrado para identificar essas situações com score máximo abaixo de 0,35, retornando resposta de fallback honesta sem custo de processamento LLM.

8. Comparação RAG vs. LLM Puro

A comparação quantitativa entre o pipeline RAG e o LLM puro (Mistral 7B sem recuperação de documentos) revela diferenças significativas e consistentes em todas as métricas avaliadas. A tabela a seguir apresenta os resultados detalhados por questão:

Questão / Categoria	Dific.	CS RAG	CS LLM	Δ (RAG-LLM)	Veredito
Q01 — Certificação LEED	Intermediária	7,5	4,2	+3,3	RAG ↑
Q02 — Certificação AQUA-HQE	Intermediária	9,0	5,3	+3,7	RAG ↑
Q03 — Normas ABNT (NBR 15575)	Avançada	6,7	2,3	+4,4	RAG ↑
Q04 — PROCEL Edifica	Intermediária	8,1	3,8	+4,3	RAG ↑
Q05 — Fotovoltaico (ABSOLAR)	Avançada	9,5	2,4	+7,1	RAG ↑↑
Q06 — Reúso de Água	Intermediária	9,2	2,6	+6,6	RAG ↑↑
Q07 — ASHRAE 90.1	Avançada	6,7	1,5	+5,2	RAG ↑↑
Q08 — Panorama IEA 2023	Básica	9,0	2,0	+7,0	RAG ↑↑
Q09 — Selo Casa Azul+	Intermediária	9,1	4,3	+4,8	RAG ↑
Q10 — BEMS (ABESCO)	Avançada	9,5	3,4	+6,1	RAG ↑↑
MÉDIA GERAL	—	8,43	3,18	+5,25	✓ APROVADO

A análise comparativa evidencia que o LLM puro apresenta três padrões recorrentes de falha. O primeiro é a imprecisão numérica: em Q01 (LEED), o LLM afirmou 'redução mínima de 20%' quando o requisito correto é 30%; em Q05 (fotovoltaico), afirmou Performance Ratio de 0,95 quando o valor típico é 0,75–0,85; em Q10 (BEMS), afirmou 'redução superior a 50%' quando a faixa documentada é 10%–30%. O segundo padrão é a ausência de rastreabilidade: 90% das respostas do LLM puro não continham nenhuma referência bibliográfica verificável. O terceiro é a confusão entre sistemas de certificação: o LLM equiparou AQUA-HQE ao LEED em metodologia (Q02) e descreveu o Selo Casa Azul como tendo 'apenas 3 categorias' quando na realidade são 6 (Q09).

O delta médio de +5,25 pontos no Composite Score representa um ganho relativo de 165% sobre a baseline LLM puro. Mais relevante do que o valor absoluto é a consistência: o RAG superou o LLM em todas as 10 questões, com o menor delta sendo +3,3 (Q01, tema parcialmente coberto pelo conhecimento paramétrico do LLM dado que LEED é amplamente discutido na literatura técnica disponível no treinamento). Os maiores ganhos (+7,0 e +7,1) ocorreram justamente nas questões onde o LLM puro demonstrou maior propensão a alucinação — valores numéricos precisos de relatórios técnicos recentes (IEA 2023) e parâmetros técnicos de engenharia (Performance Ratio fotovoltaico).

9. Impacto do Pipeline RAG

O impacto do pipeline RAG é analisado em três dimensões: impacto na qualidade técnica das respostas, impacto na confiança do usuário e impacto operacional em um cenário profissional real.

Em termos de qualidade técnica, o RAG transforma o LLM de um gerador de texto plausível em um assistente técnico auditável. A marcação estruturada [T1]–[T5] com indicação de seção e página garante que cada afirmação pode ser verificada no documento original em segundos — uma característica indispensável para profissionais que elaboram projetos de certificação LEED ou AQUA-HQE, onde um requisito incorreto pode resultar em perda de créditos ou rejeição pela entidade certificadora. A Numeric Precision Rate de 98% para o RAG versus 27% para o LLM puro quantifica essa diferença: o RAG preserva os valores exatos do corpus, enquanto o LLM os arredonda ou interpola.

Em termos de confiança do usuário, a estrutura de resposta obrigatória — Resposta técnica, Documentos consultados, Trechos utilizados, Fontes — provê transparência metodológica que permite ao usuário calibrar seu próprio nível de ceticismo. O campo `response_confidence` (0,0–1,0) calculado pelo pipeline oferece uma métrica objetiva de qualidade por consulta, viabilizando um sistema de alerta quando a confiança cai abaixo de 0,5. O LLM puro, por construção, não oferece nenhum mecanismo análogo.

Em termos operacionais, o pipeline RAG elimina a necessidade de o profissional pesquisar manualmente em dezenas de documentos técnicos para encontrar um requisito específico. A latência média de 11 segundos por consulta (Mistral 7B em CPU) é aceitável para um fluxo de trabalho de consultoria técnica, especialmente considerando que substitui minutos ou horas de pesquisa manual. A arquitetura modular com fallback automático para Qwen 2.5 3B garante disponibilidade mesmo em hardware com menos de 8GB de RAM.

10. Limitações do Sistema

A principal limitação técnica identificada é a degradação do sistema em perguntas que exigem raciocínio composto sobre múltiplos documentos. Quando a resposta completa

requer integração de informações de três ou mais fontes distintas — por exemplo, comparar os requisitos hídricos do LEED, AQUA-HQE e Selo Casa Azul+ simultaneamente — o pipeline retorna os 5 chunks mais relevantes, que frequentemente são todos do mesmo documento (o mais específico para a query). O mecanismo de cross-reference expansion mitiga parcialmente esse problema, mas não resolve casos onde a pergunta é genuinamente cross-corpus.

A segunda limitação é a dependência de infraestrutura local significativa. O Mistral 7B em quantização Q4 requer 4,1 GB de RAM apenas para o modelo, mais o overhead do sistema operacional e do ChromaDB. Em máquinas com 8 GB de RAM, a geração pode ser lenta (15–25 segundos por consulta em CPU). O modelo de embedding multilingual-e5-large adiciona mais 1,2 GB. Essa combinação limita a portabilidade do sistema para ambientes com hardware restrito, demandando ou o uso do modelo fallback (Qwen 2.5 3B) ou a migração para uma API de LLM externa — o que introduz custos e dependências de conectividade.

A terceira limitação é o HDR (Hallucination Detection Rate) de 31,7% para o RAG, acima do threshold desejado de 20%. A análise detalhada revela que esse valor é parcialmente inflado pelo método de detecção, que utiliza correspondência de strings para identificar armadilhas — um método conservador que pode gerar falsos positivos quando um valor numérico de uma armadilha coincide com um valor correto de contexto diferente. A implementação atual não distingue entre 'o sistema afirmou 20% de forma incorreta' e 'o sistema mencionou 20% em contexto correto (ex.: como contra-exemplo)'. O refinamento do verificador de alucinação para análise contextual, não apenas léxica, é a melhoria mais urgente identificada.

Adicionalmente, o sistema apresenta limitação de atualização temporal. O corpus é estático: normas que são revisadas (ex.: ABNT NBR 15575 passou por revisão em 2022) exigem reindexação manual. Não há mecanismo automático de detecção de desatualização de documentos. Em um cenário de uso profissional de longo prazo, o custo operacional de manutenção do corpus é um fator não negligenciável.

11. Melhorias Futuras

Com base nas limitações identificadas e nos resultados da avaliação, propõem-se cinco melhorias prioritárias para versões futuras do sistema, ordenadas por impacto esperado sobre a qualidade das respostas:

- Multi-hop Retrieval para perguntas cross-corpus: implementar um mecanismo de Chain-of-Thought Retrieval onde a resposta parcial de uma primeira recuperação alimenta uma segunda query ao ChromaDB. Isso permitiria responder adequadamente a perguntas comparativas como 'Qual certificação tem requisito hídrico mais rigoroso: LEED ou AQUA-HQE?' — atualmente respondidas apenas com o documento que tiver maior score de relevância para a query original.
- Verificação contextual de alucinação com NLI (Natural Language Inference): substituir a detecção por correspondência de strings por um modelo de NLI leve

(ex.: cross-encoder/nli-deberta-v3-small) que classifique cada afirmação da resposta como Entailment, Contradiction ou Neutral em relação aos chunks do contexto. Isso reduziria a taxa de falsos positivos do HallucinationChecker e forneceria uma medida mais robusta de HDR.

- Expansão do corpus com atualização automática: desenvolver um pipeline de monitoramento que detecta novas versões de normas técnicas (via RSS do portal ABNT e portais das entidades certificadoras) e dispara automaticamente o fluxo de reindexação quando uma atualização é identificada. Integrar checksum de versão nos metadados para facilitar a comparação entre versões.
- Interface conversacional com memória de sessão: implementar gerenciamento de contexto multi-turno para que o assistente consiga refinar respostas com base em perguntas de acompanhamento. A arquitetura atual trata cada consulta de forma independente; um sistema de histórico de conversa permitiria interações como 'E no caso de edificações industriais, como esse requisito muda?'
- Avaliação humana especializada: conduzir um estudo de avaliação com 3 especialistas independentes (engenheiro ambiental, arquiteto com experiência em certificação e consultor LEED credenciado) utilizando protocolo de duplo-cego para pontuação de Factual Claim Accuracy (FCA). As métricas automáticas implementadas são necessárias mas não suficientes para validação em contexto de uso profissional — a avaliação humana é o padrão-ouro para sistemas de informação técnica especializada.

Verificação dos Critérios de Sucesso

A tabela a seguir sumariza a verificação formal dos critérios de sucesso estabelecidos para o pipeline RAG:

Critério de Sucesso	Threshold	Obtido	Status
CS médio RAG $\geq 7,0/10$	$\geq 7,0/10$	8,43/10	✓ ATINGIDO
Delta CS $\geq +3,0$ em $\geq 8/10$ questões	8/10 qs.	10/10 qs.	✓ ATINGIDO
NPR médio (precisão numérica) $\geq 80\%$	$\geq 80\%$	98%	✓ ATINGIDO
STS médio (rastreabilidade) $\geq 70\%$	$\geq 70\%$	92%	✓ ATINGIDO
HDR médio (alucinação) $\leq 20\%$	$\leq 20\%$	31,7%	PARCIAL

Considerações Finais

O pipeline Sueteres RAG Assistant demonstrou, nos experimentos realizados, que a abordagem de Retrieval-Augmented Generation produz sistematicamente respostas de maior qualidade, precisão e rastreabilidade do que o uso direto de um LLM sem contexto externo, no domínio técnico de edificações sustentáveis. O ganho médio de +5,25 pontos no Composite Score (165% de melhoria relativa sobre a baseline) é estatisticamente expressivo e consistente entre categorias de dificuldade e domínios temáticos.

O elemento diferencial mais crítico do sistema não é a qualidade intrínseca do LLM — o Mistral 7B é um modelo de qualidade moderada para um assistente de uso geral —, mas sim a estrutura do pipeline que o envolve: o guardrail pré-LLM que elimina consultas fora do domínio sem custo computacional, o sistema de marcação [T1]–[T5] que transforma a resposta em um documento auditável, e a verificação pós-geração que sinaliza discrepâncias numéricas. Esses mecanismos, combinados, produzem um sistema cujo comportamento é previsível, explicável e verificável — atributos fundamentais para adoção em contextos profissionais onde a precisão técnica tem consequências diretas sobre decisões de projeto e certificação ambiental.

O projeto cumpre os requisitos da disciplina ao demonstrar a aplicação prática dos conceitos de Computational Thinking — decomposição do problema em módulos, abstração de interfaces, reconhecimento de padrões na estrutura documental e generalização da solução para múltiplos formatos e idiomas — em um sistema funcional, testado (101 testes automatizados passando) e avaliado quantitativamente com metodologia rigorosa.

Referências documentais completas disponíveis em: `./evaluation/evaluation_results.json`
e `./evaluation/avaliacao_rag.ipynb`